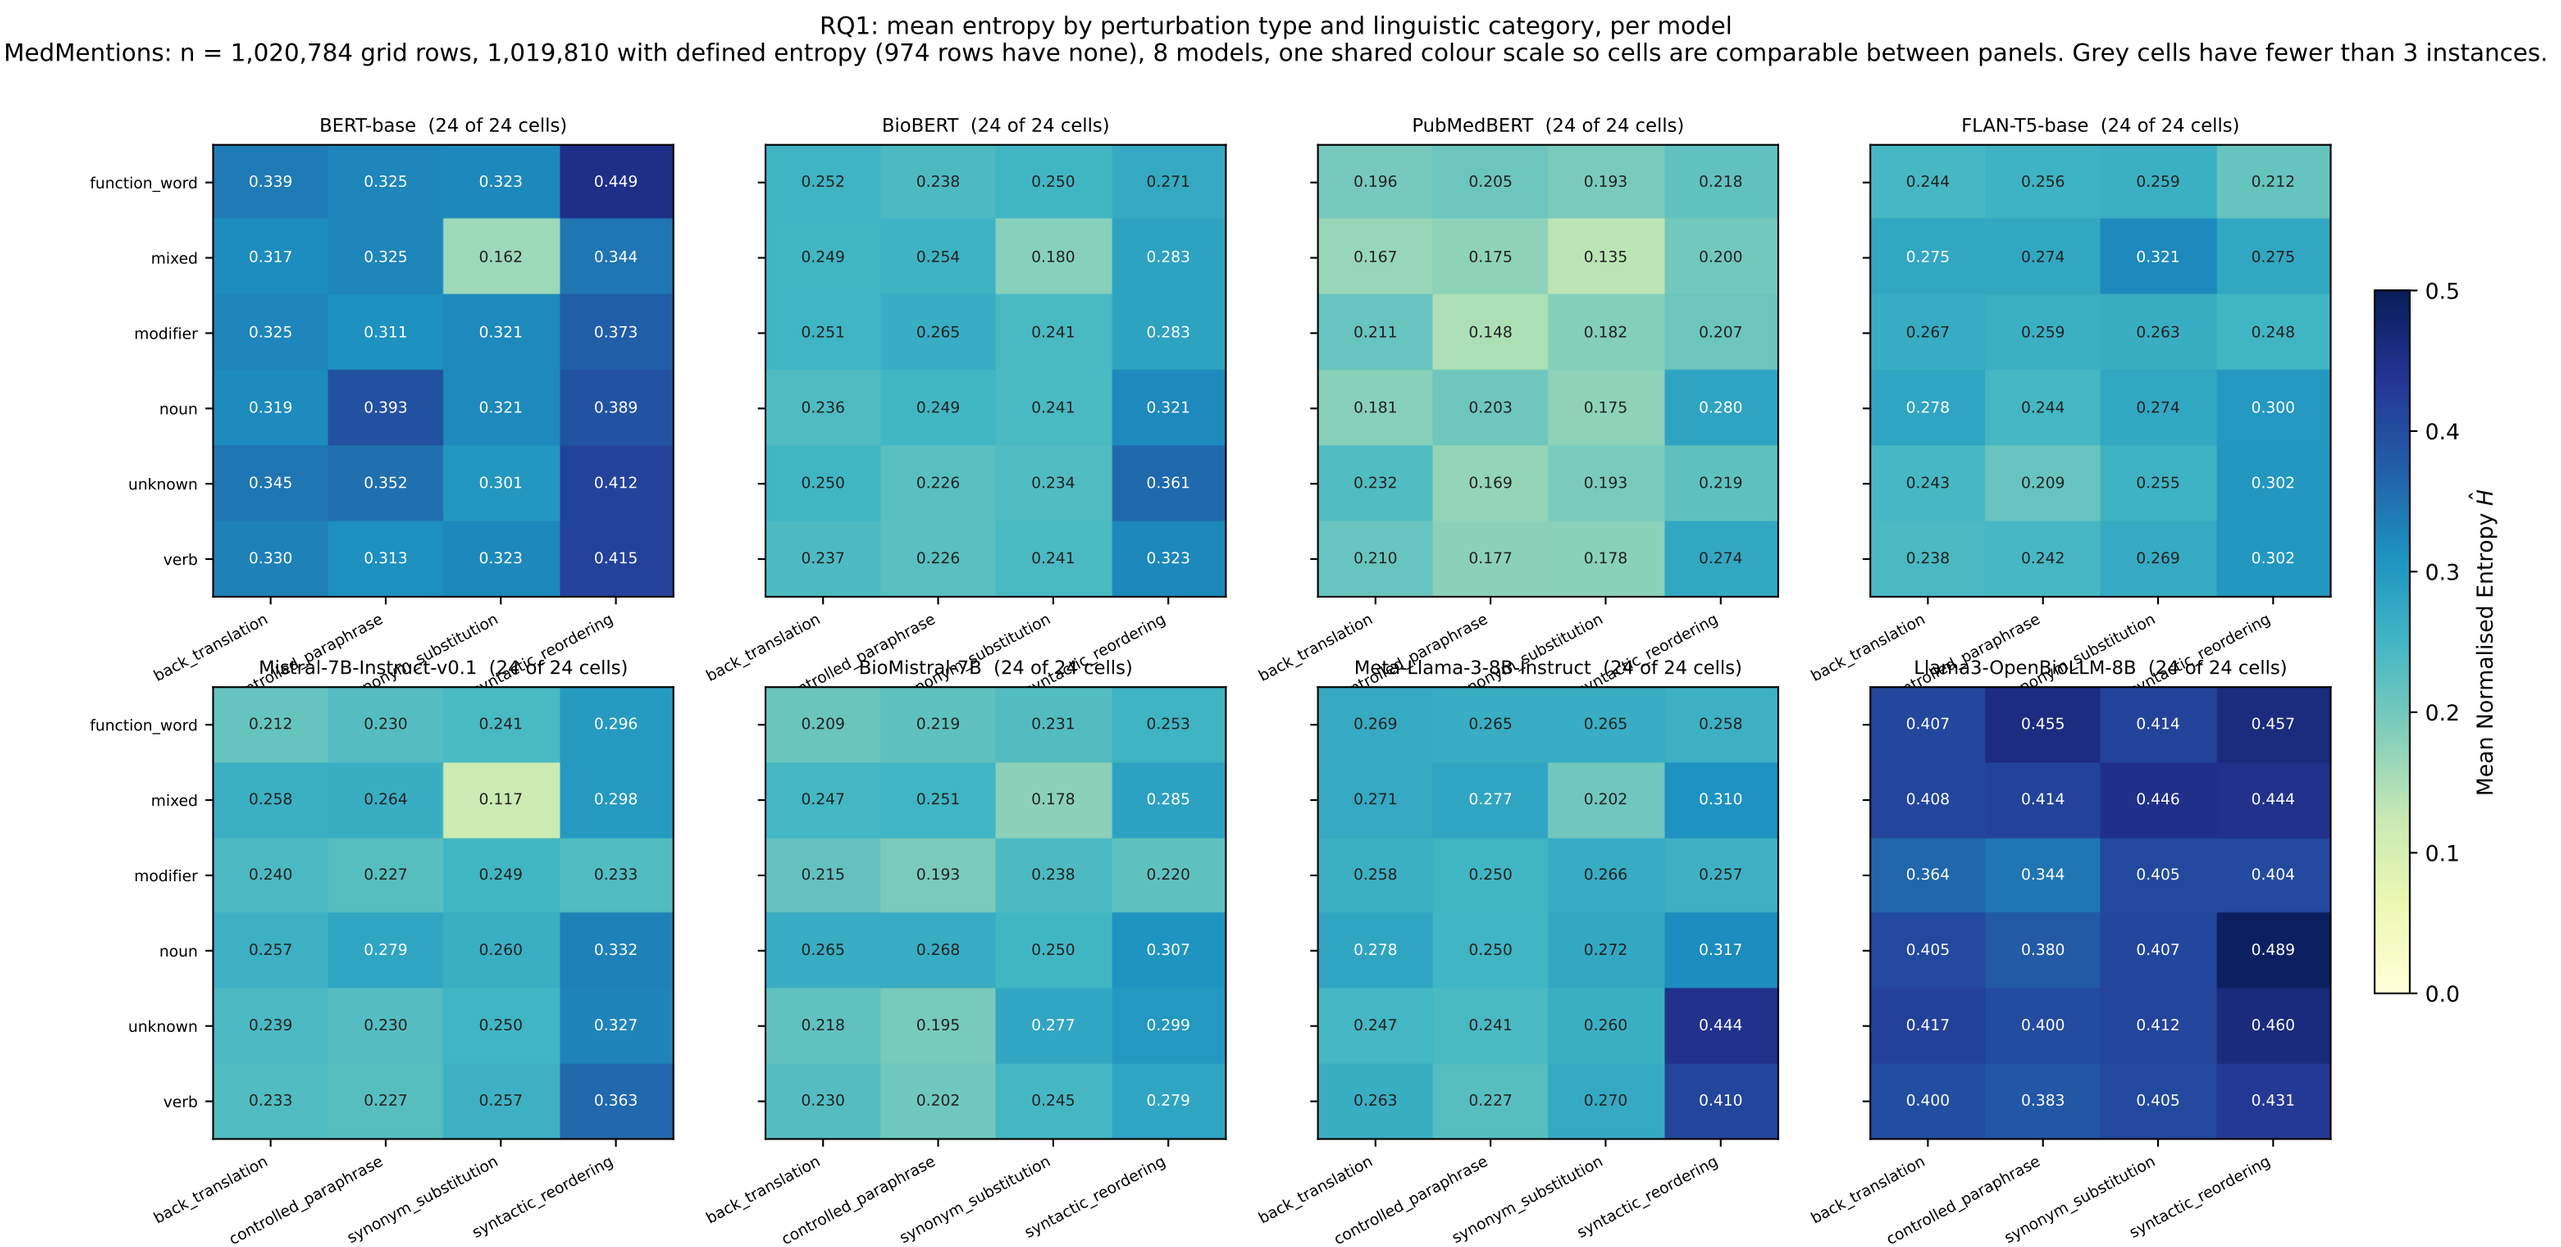
RQ1: mean entropy by perturbation type and linguistic category, per model
MedMentions: n = 1,020,784 grid rows, 1,019,810 with defined entropy (974 rows have none), 8 models, one shared colour scale so cells are comparable between panels. Grey cells have fewer than 3 instances.
BERT-base (24 of 24 cells)
BioBERT (24 of 24 cells)
PubMedBERT (24 of 24 cells)
FLAN-T5-base (24 of 24 cells)
Mistral-7B-Instruct-v0.1 (24 of 24 cells)
BioMistral-7B (24 of 24 cells)
Meta-Llama-3-8B-Instruct (24 of 24 cells)
Llama3-OpenBioLLM-8B (24 of 24 cells)
function_word
mixed
modifier
noun
unknown
verb
back_translation
controlled_paraphrase
synonym_substitution
syntactic_reordering
0.339 0.325 0.323 0.449
0.317 0.325 0.162 0.344
0.325 0.311 0.321 0.373
0.319 0.393 0.321 0.389
0.345 0.352 0.301 0.412
0.330 0.313 0.323 0.415
0.252 0.238 0.250 0.271
0.249 0.254 0.180 0.283
0.251 0.265 0.241 0.283
0.236 0.249 0.241 0.321
0.250 0.226 0.234 0.361
0.237 0.226 0.241 0.323
0.196 0.205 0.193 0.218
0.167 0.175 0.135 0.200
0.211 0.148 0.182 0.207
0.181 0.203 0.175 0.280
0.232 0.169 0.193 0.219
0.210 0.177 0.178 0.274
0.244 0.256 0.259 0.212
0.275 0.274 0.321 0.275
0.267 0.259 0.263 0.248
0.278 0.244 0.274 0.300
0.243 0.209 0.255 0.302
0.238 0.242 0.269 0.302
0.212 0.230 0.241 0.296
0.258 0.264 0.117 0.298
0.240 0.227 0.249 0.233
0.257 0.279 0.260 0.332
0.239 0.230 0.250 0.327
0.233 0.227 0.257 0.363
0.209 0.219 0.231 0.253
0.247 0.251 0.178 0.285
0.215 0.193 0.238 0.220
0.265 0.268 0.250 0.307
0.218 0.195 0.277 0.299
0.230 0.202 0.245 0.279
0.269 0.265 0.265 0.258
0.271 0.277 0.202 0.310
0.258 0.250 0.266 0.257
0.278 0.250 0.272 0.317
0.247 0.241 0.260 0.444
0.263 0.227 0.270 0.410
0.407 0.455 0.414 0.457
0.408 0.414 0.446 0.444
0.364 0.344 0.405 0.404
0.405 0.380 0.407 0.489
0.417 0.400 0.412 0.460
0.400 0.383 0.405 0.431
Mean Normalised Entropy $\hat{H}$
0.0
0.1
0.2
0.3
0.4
0.5